交通时空大数据分析与可视化系统 — 14天授课笔记（第2版）

> 技术栈：Python 3 + NumPy + Pandas + Matplotlib
> 课时：14天 × 8课时/天 = 112课时
> 数据：沈阳2018-10-03信令数据（约53万行）+ 基站表 + 商圈/目的/方式静态数据 + 实时流

一、课程定位

本课程以"交通时空大数据分析系统"真实项目为载体，带领学生从原始信令数据出发，完整实现：数据清洗 → 出行/驻留识别 → 出行目的推断 → 出行方式推断 → 实时商圈热力 → 结果可视化。

全程使用 Python 三件套（NumPy/Pandas/Matplotlib），不依赖 Hadoop/Spark/Kafka/MySQL/echarts，降低环境门槛，聚焦算法与业务逻辑。

二、14天课程总表

Day01 项目导学与开发环境搭建

课时	主题	核心内容
1	项目背景与业务目标	信令数据是什么、能做什么、系统整体架构图、各模块输入输出
2	数据集全景解读	7个数据文件的字段、编码、行数、样例数据、数据间关联关系
3	Python环境搭建与验证	Anaconda/原生Python安装、pip换源、numpy/pandas/matplotlib安装验证
4	Jupyter Notebook与VS Code	两种开发环境对比、快捷键、调试技巧、项目目录结构规范
5	Python基础速览（上）	变量/类型/运算符/条件/循环/函数/异常，重点讲与C/Java的差异
6	Python基础速览（下）	列表/字典/集合/元组/推导式/文件读写/with语句
7	模块化与包管理	import机制、**init**.py、相对/绝对导入、requirements.txt
8	第一个可运行脚本	读取CSV、统计行数、打印字段、保存结果，建立"读-算-写"工程习惯

Day02 NumPy核心与向量化计算

课时	主题	核心内容
1	NumPy设计思想	为什么需要NumPy、ndarray内存布局、向量化vs循环的性能本质
2	ndarray创建与属性	array/arange/linspace/zeros/ones/random、shape/dtype/ndim/size
3	索引与切片	一维/二维索引、布尔索引、花式索引、视图vs副本（内存共享坑）
4	广播机制	广播规则详解、不同shape数组运算、广播的内存优化
5	常用数学与统计函数	sum/mean/std/var/min/max/argmax/cumsum、axis参数的本质
6	矩阵运算与线性代数	dot/matmul/@、转置、逆矩阵、特征值、本项目距离计算中的应用
7	性能对比实验	Python循环 vs NumPy向量化 vs Pandas apply，实测10万/100万行耗时
8	项目实战：Haversine距离向量化	球面距离公式推导、向量化实现、10万点距离矩阵计算

Day03 Pandas数据处理核心

课时	主题	核心内容
1	Pandas设计思想与数据结构	Series/DataFrame/Index的关系、与Excel/数据库的对比
2	CSV读取与类型推断	read_csv参数详解、header/names/dtype/encoding/nrows、类型推断陷阱
3	数据探查	head/tail/info/describe/value_counts/isnull/duplicated
4	索引与选择	loc/iloc/at/iat、布尔过滤、query方法、链式赋值警告
5	缺失值与重复值处理	dropna/fillna/interpolate、drop_duplicates、缺失值业务含义
6	分组聚合	groupby机制、agg/transform/apply、多列聚合、分组后过滤
7	表合并与连接	merge/join/concat、inner/left/right/outer、关联键设计
8	时间序列处理	to_datetime、dt访问器、时间差、按时间分组、时区问题

Day04 Matplotlib可视化与图表设计

课时	主题	核心内容
1	Matplotlib架构	figure/axes/artist三层架构、OO风格vs pyplot风格
2	折线图与趋势分析	plot参数、多系列对比、双Y轴、填充区域、时间轴格式化
3	柱状图与对比分析	bar/barh、堆叠柱状、分组柱状、数值标签、误差棒
4	散点图与空间分布	scatter、颜色映射cmap、点大小映射、透明度、colorbar
5	饼图与占比分析	pie、环形图、突出扇区、百分比标签、饼图适用场景与局限
6	直方图与箱线图	hist、bins选择、箱线图五数概括、离群点识别、小提琴图
7	子图布局与Dashboard	subplots/gridspec、suptitle、tight_layout、2×3大屏布局
8	3D可视化与时空轨迹	projection=3d、3D散点/曲面/轨迹、视角调整、颜色映射时间

Day05 数据清洗模块（9条规则深度实现）

课时	主题	核心内容
1	清洗业务需求与9条规则详解	每条规则的业务含义、为什么需要、不清洗的后果
2	原始数据读取与字段抽取	10列原始字段解析、dtype=str的必要性、为什么lac_id/cell_id不能用数字
3	脏imsi过滤与空间残缺过滤	正则匹配特殊字符、三列空值/000校验、过滤顺序的性能考量
4	时间戳转换与日期过滤	13位毫秒时间戳原理、to_datetime(unit=ms)、strftime格式化、按日过滤
5	基站表关联补全经纬度（核心）	laci拼接键设计、左关联merge、关联失败分析、经纬度补全率统计
6	排序与分钟去重	按imsi+time排序、分钟粒度去重原理、乒乓噪声抑制
7	样本量过滤与标准表输出	单imsi≥20条的业务理由、transform过滤、标准表字段设计
8	完整清洗流水线与质量报告	整合9条规则、各步过滤量统计、清洗质量评估、结果保存

Day06 数据分析与调研（算法选型依据）

课时	主题	核心内容
1	调研目标与方法论	为什么开发前要调研、调研要回答什么问题、调研结论如何指导算法
2	数据质量诊断	行数/用户数/经纬度范围/时间覆盖/缺失率/异常值检测
3	单用户轨迹提取与可视化	按imsi筛选、时间排序、2D散点+3D轨迹、颜色映射时间
4	数据频次特征分析	相邻记录时间间隔分布、长时低频vs短时高频、活跃时段识别
5	空间位移特征分析	相邻点Haversine距离分布、大位移噪声识别、驻留vs出行的位移差异
6	乒乓切换噪声分析	基站间来回切换的识别、乒乓对聚类的影响、去重策略的必要性
7	调研结论与算法选型	三条发现→无监督聚类选型、k-means适用性分析、为什么不用有监督分类
8	样本抽取与区间分布分析	按记录数分层抽样、不同活跃度用户轨迹对比、样本代表性验证

Day07 出行&驻留·阶段1（数据预处理）

课时	主题	核心内容
1	三阶段框架与阶段1目标	为什么分三阶段、阶段1的作用（先剔除明显出行点）、输入输出
2	低频点提取原理与实现	出现次数<4的业务含义、groupby+transform回填、低频点占比统计
3	全局顺序号与连续段识别	cumcount赋序号、连续段切分算法、首/中/尾点连续性规则
4	连续段时间跨度计算	首末时间差、单点段处理、时间跨度分布分析
5	连续段距离跨度计算	相邻点球面距离累加、向量化实现、距离跨度分布
6	平均速度计算与阈值判定	速度=距离/时间、>8km/h判出行的业务依据、速度分布与阈值选择
7	出行点输出与阶段1结果分析	出行点CSV输出、出行段统计、速度分布可视化、阶段1效果评估
8	阶段1完整代码整合与调试	整合为stage1()函数、边界条件处理、性能优化、常见bug排查

Day08 出行&驻留·阶段2（k-means聚类）

课时	主题	核心内容
1	阶段2目标与聚类思路	去除出行点后的剩余点、为什么用聚类、k-means vs DBSCAN vs层次聚类
2	k-means算法原理深度讲解	目标函数SSE、EM迭代过程、收敛性分析、初始中心敏感性、空簇问题
3	手写k-means实现	初始化/分配/更新/收敛四步、向量化距离矩阵、空簇保护、SSE计算
4	数据预处理与特征工程	经纬度转向量、是否需要标准化、经纬度尺度差异的影响
5	遍历K=2~10与多指标评估	K的搜索范围、为什么不能只看SSE、三大评估指标原理
6	邓恩指数（DVI）深度讲解	簇间最小距离/簇内最大直径、DVI越大越好、DVI计算实现、DVI选K
7	轮廓系数与SSE肘部法则	轮廓系数(a,b)公式、肘部法则原理、三指标对比与综合选K
8	阶段2完整实现与结果分析	最优K分布统计、簇标签输出、聚类效果可视化、阶段2→阶段3衔接

Day09 出行&驻留·阶段3（业务逻辑判定）

课时	主题	核心内容
1	阶段3目标与判定规则总览	簇→业务标签的转换、距离+时间双维度判定、首/中/尾点规则差异
2	按imsi-簇分组与簇中心计算	groupby聚合、簇中心=经纬度均值、簇中心的业务含义
3	点到簇中心距离计算	Haversine距离、距离阈值1000m的业务依据、距离分布分析
4	相邻点时间跨度计算	groupby.diff()、前向/后向时间差、首点/尾点NaN处理
5	首点判定逻辑	首点无前置点、用与下一点时间跨度、首点判驻留的业务合理性
6	中间点与尾点判定逻辑	中间点用可用时间跨度、尾点用与上一点跨度、距离超阈值一律出行
7	标签输出与结果验证	0驻留/1出行标签、标签分布统计、抽样人工验证、阶段3效果评估
8	三阶段串联与出行驻留模块总结	阶段1→2→3数据流、各阶段贡献、整体准确率评估、模块优化方向

Day10 出行目的识别

课时	主题	核心内容
1	出行目的识别业务目标	为什么要识别目的、目的类别定义（居住/购物/旅游/其他）、输入输出
2	驻留段识别与归并	从标签取驻留点、相邻驻留点归并成段、归并阈值选择、段数统计
3	驻留段特征提取	起始/结束时间、时长、段中心经纬度、时段特征（start_h/end_h）
4	居住判定规则深度讲解	时长>4h、0-6点起/20-24点止、过夜段的业务含义、居住段统计
5	购物与旅游判定规则	购物9-21点、旅游9-17点、规则重叠与优先级设计、多类别冲突处理
6	目的静态数据读取与匹配	GBK编码处理、目的点坐标、<1km取最近的匹配逻辑、匹配率统计
7	出行目的结果输出与分析	目的分布统计、各目的时段特征、目的识别效果评估、典型案例分析
8	目的识别模块完整实现与优化	整合为purpose()、规则参数化、边界情况处理、与出行驻留模块的衔接

Day11 出行方式识别

课时	主题	核心内容
1	出行方式识别业务目标	为什么要识别方式、方式类别（地铁/公交/小汽车/其他）、速度+空间双维度
2	出行段识别与归并	从标签取出行点、相邻出行点归并、出行段与驻留段的归并阈值差异
3	出行段平均速度计算	段内距离累加/时间跨度、速度分布分析、速度阈值的业务依据
4	速度规则初判	>20km/h地铁或小汽车、>12km/h公交、≤12km/h其他、速度分档的合理性
5	方式静态数据读取	GBK编码、地铁站/公交站坐标、数据结构、方式点覆盖范围
6	地铁空间匹配（≥2点 <500m）	为什么要求≥2点、500m阈值依据、匹配计数实现、地铁段判定
7	公交空间匹配与小汽车兜底	公交≥3点的原因、匹配不上且高速→小汽车、低速→其他、方式分布统计
8	出行方式模块完整实现与分析	整合为mode()、方式分布可视化、典型出行段案例分析、模块优化方向

Day12 实时商圈热力图

课时	主题	核心内容
1	实时热力业务目标与架构	实时热力回答什么问题、流数据+商圈数据+滑窗计数的架构设计
2	实时流数据读取与预处理	流数据字段、时间格式统一、imsi字符串读取、分钟粒度提取
3	商圈静态数据读取	商圈点坐标、商圈清单、商圈覆盖范围、商圈数据质量检查
4	流点商圈匹配算法	最近商圈查找、距离阈值设计、未命中点处理、匹配率统计
5	滑动时间窗口原理	过去10分钟窗口定义、窗口边界、逐分钟滑动、滑窗vs固定窗口
6	窗口内商圈人次统计	窗口筛选+groupby计数、时间×商圈×人次输出、滑窗计数性能优化
7	实时热力结果输出与分析	各商圈全天人次、热门商圈排名、人流随时间变化、峰值时段识别
8	热力图模块完整实现与优化	整合为heatmap()、滑窗参数化、大数据量性能优化、与可视化模块衔接

Day13 结果可视化与大屏

课时	主题	核心内容
1	可视化整体规划与图表选型	6类业务结果→6种图表、图表选型原则、数据→图表的映射关系
2	统一中文字体与样式配置	rcParams配置、SimHei/Microsoft YaHei、负号显示、统一dpi/figsize
3	出行/驻留占比饼图	value_counts统计、pie参数、颜色设计、百分比标签、占比解读
4	出行目的与方式柱状图	类别排序、颜色映射、数值标签、双图对比布局、柱状图解读
5	各小时活跃折线图	按小时groupby、24小时补零、早高峰/晚高峰标注、网格与样式
6	商圈热力可视化	商圈总人次柱状、多商圈时间序列对比、热力矩阵、热门商圈突出
7	3D时空轨迹图	单用户轨迹提取、经度×纬度×小时、颜色映射时间、连线显示移动、视角调整
8	Dashboard大屏组装	2×3子图布局、suptitle总标题、tight_layout、统一配色、大屏导出

Day14 系统整合与答辩

课时	主题	核心内容
1	系统整体架构回顾	模块依赖图、数据流全景、各模块输入输出、架构设计原则
2	main.py主流程设计	7步流水线、函数调用顺序、异常处理、日志输出、main入口规范
3	config.py参数集中管理	阈值/路径/编码集中、魔法数字消除、参数可配置性、配置文件最佳实践
4	utils.py工具函数复用	haversine/setup_zh/read_csv等公共函数、复用原则、循环依赖避免
5	抽样运行vs全量运行	抽样的必要性、nrows参数、抽样对结果的影响、全量运行的性能考量
6	运行计时与产物核对	time模块计时、各步耗时分析、产物清单核对、文件完整性检查
7	工程化最佳实践总结	模块化/可配置/可复用/可测试/可维护、代码规范、注释规范、项目结构
8	结课答辩准备	答辩PPT结构、3分钟自述、技术亮点提炼、常见问题准备、成果展示

三、技术栈说明

技术	版本	用途
Python	3.10+	主语言
NumPy	1.24+	向量化计算、距离矩阵
Pandas	2.0+	数据清洗、分组聚合、表关联
Matplotlib	3.7+	全部可视化图表

> 不使用 sklearn（k-means手写，锻炼算法能力）、不使用 geopandas（经纬度直接用 Haversine）。

四、数据文件清单

文件	行数	编码	字段
原始数据.csv	~53万	UTF-8	timestamp,imsi,lac_id,cell_id,phone,timestamp1,tmp0,tmp1,nid,npid
基站经纬度数据.csv	49954	UTF-8	longitude,latitude,laci
商业区数据.csv	104	UTF-8	longitude,latitude,商圈名
出行目的静态数据.csv	1273	GBK	longitude,latitude,目的类别,目的名
出行方式静态数据.csv	968	GBK	方式类型,longitude,latitude,...
实时流数据.csv	256212	UTF-8	时间,imsi,经度,纬度
hive模块静态数据.csv	225	UTF-8	区域名,laci

五、评分标准（参考）

维度	占比	说明
代码可运行性	30%	各模块能独立运行、main.py一键跑通
业务逻辑正确性	30%	9条清洗规则、三阶段判定、目的/方式规则正确实现
可视化完整性	20%	6张业务图+Dashboard，中文正常、数据准确
代码规范与注释	10%	模块化、参数集中、逐行注释、命名清晰
答辩表现	10%	能讲清业务逻辑、算法原理、成果结论